

Документация за курсов проект по „Бази от знания“: NutriEvidence Knowledge Graph и node2vec

Явор Чамов

Факултетен №: 4MI3400787

8 юни 2026 г.

Резюме

Настоящият документ описва частта от проекта *NutriEvidence Agent*, която е свързана с дисциплината „Бази от знания“. Акцентът е поставен върху моделирането на биомедицински знания чрез Article–MeSH knowledge graph, представянето на статии и медицински термини като графови възли, обучението на node2vec ембединги и използването им за препоръчване на сходни научни публикации.

Съдържание

1	1. Резюме / Abstract	4
2	2. Проблем, който проектът решава	4
3	3. Основна цел на проекта за предмета „Бази от знания“	5
4	4. Какво представлява базата от знания в проекта	5
5	5. Представяне на знанията	6
5.1	5.1. Типове възли	6
5.2	5.2. Типове релации	7
5.3	5.3. Данни, използвани за графа	7

6	6. Изграждане на Article–MeSH knowledge graph	7
6.1	6.1. Зареждане на статии	8
6.2	6.2. Нормализация на MeSH термините	8
6.3	6.3. Добавяне на възли и ребра	8
6.4	6.4. Общ алгоритъм	9
6.5	6.5. Визуализация на Article–MeSH графа	9
7	7. MeSH overlap baseline	10
8	8. node2vec върху knowledge graph	10
8.1	8.1. Идея на node2vec	10
8.2	8.2. Random walks	11
8.3	8.3. Параметри на node2vec	11
8.4	8.4. Обучение на embeddings	12
8.5	8.5. Визуализация на node2vec embedding пространството	12
9	9. Graph-based recommender	14
9.1	9.1. Recommend by selected article	14
9.2	9.2. Общ процес	15
9.3	9.3. Изход от recommender-a	15
10	10. Архитектура на knowledge graph модула	15
10.1	10.1. ArticleMeshGraphBuilder	16
10.2	10.2. Node2VecTrainer	16
10.3	10.3. GraphRecommender	16
11	11. Хипотези	17
11.1	11.1. Хипотеза H1: MeSH термините са подходяща основа за база от знания	17
11.2	11.2. Хипотеза H2: node2vec улавя структурна близост между статии .	17
11.3	11.3. Хипотеза H3: Графовият подход е обясним	17

12	12. Оценяване	18
12.1	12.1. Evaluation scenario	18
12.2	12.2. Метрики	18
12.3	12.3. Примерна таблица за резултати	19
13	13. Реализация	19
13.1	13.1. Използвани технологии	19
13.2	13.2. Данни и artifacts	19
13.3	13.3. Псевдокод на GraphRecommender	20
14	14. Ограничения	20
15	15. Бъдеща работа	21
16	16. Очакван принос на проекта	21
17	17. Заключение	21

1 1. Резюме / Abstract

NutriEvidence Knowledge Graph представлява модул от проекта *NutriEvidence Agent*, който моделира връзките между PubMed статии и техните MeSH термини като база от знания. Вместо публикациите да се разглеждат само като независими текстови документи, те се представят като част от графова структура, в която статии, медицински понятия и тематични категории са свързани чрез експлицитни релации.

Основната идея е, че биомедицинската литература съдържа не само текстова информация, но и структурирани знания. MeSH термините са контролирани медицински понятия, чрез които публикациите се индексират в PubMed. Когато статия е свързана с даден MeSH термин, това означава, че тя разглежда конкретна медицинска тема, заболяване, популация, метод или изследователски контекст.

В проекта тези връзки се използват за изграждане на **Article–MeSH knowledge graph**. Върху графа се обучава **node2vec** модел, който генерира векторни представления на възлите. След това embeddings на article възлите се използват за намиране на сходни статии чрез cosine similarity.

Така системата добавя графово знание към препоръчването на научни публикации. Това е особено подходящо за предмета „Бази от знания“, защото проектът демонстрира как домейн знания могат да бъдат моделирани, съхранявани, обработвани и използвани за изводи и препоръки.

2 2. Проблем, който проектът решава

PubMed съдържа голямо количество биомедицински публикации. Всяка публикация може да бъде свързана с множество медицински понятия, като заболявания, симптоми, възрастови групи, методи на изследване, хранителни фактори и клинични показатели. Ако тези връзки се разглеждат само като списък от ключови думи, се губи важна структурна информация.

Основните проблеми са:

- трудно е да се открият статии, които са тематично близки, но не използват еднакви думи в заглавието или abstract-a;
- semantic similarity върху текст може да пропусне връзки, които са видими през общи MeSH термини;
- простото съвпадение на MeSH термини не отчита структурата на целия набор от статии;
- липсва ясно представяне на знанията като възли, релации и домейн понятия;

- потребителят има нужда от обяснима препоръка, основана не само на текст, но и на концептуална близост.

Проектът решава тези проблеми чрез изграждане на графова база от знания, в която статиите и MeSH термините са свързани. Върху този граф се прилага node2vec, за да се получи числово представяне на структурната близост между публикациите.

3. Основна цел на проекта за предмета „Бази от знания“

Основната цел е да се разработи и документира knowledge graph модул, който:

- представя PubMed статии като възли в граф;
- представя MeSH термините като отделни концептуални възли;
- създава релации между статии и MeSH термини;
- използва графовата структура като база от знания;
- обучава node2vec embeddings върху графа;
- намира сходни статии чрез graph-based similarity;
- позволява сравнение между MeSH overlap baseline и node2vec подход;
- подпомага препоръчването на научна литература чрез структурирани знания.

Фокусът не е върху LLM слоя, генерацията на отговори или медицински съвети. Фокусът е върху моделирането и използването на знания чрез граф.

4. Какво представлява базата от знания в проекта

В контекста на проекта базата от знания е графова структура, която описва връзките между научни статии и медицински понятия. Тя може да бъде разглеждана като опростен knowledge graph, в който фактите са представени чрез тройки от вида:

```
subject --relation--> object
```

За проекта основният тип тройка е:

```
Article --hasMeSHTerm--> MeSHTerm
```

Пример:

```
article:37656239 --hasMeSHTerm--> mesh:cerebral_palsy
article:37656239 --hasMeSHTerm--> mesh:child
article:37656239 --hasMeSHTerm--> mesh:body_composition
```

Тази структура позволява системата да отговори на въпроси като:

- кои статии са свързани с даден MeSH термин;
- кои статии споделят общи медицински понятия;
- кои MeSH термини са най-често срещани в корпуса;
- кои статии са графово близки до избрана seed статия;
- кои теми свързват две публикации.

5 5. Представяне на знанията

5.1 5.1. Типове възли

Графът съдържа два основни типа възли:

Тип възел	Описание
Article	Представя PubMed публикация. Всеки article възел се идентифицира чрез PMID.
MeSHTerm	Представя медицински термин от MeSH речника, свързан с една или повече статии.

Примерни article възли:

```
article:37656239
article:12345678
article:98765432
```

Примерни MeSH възли:

```
mesh:cerebral_palsy
mesh:nutritional_status
mesh:child
mesh:body_composition
```

5.2 5.2. Типове релации

Основната релация в текущия MVP е:

Релация	Значение
hasMeSHTerm	Свързва PubMed статия с MeSH термин, който описва съдържанието ѝ.

Пример:

```
article:37656239 --hasMeSHTerm--> mesh:cerebral_palsy
```

В бъдеща версия могат да се добавят и други релации, например:

- `publishedIn` — връзка между статия и списание;
- `writtenBy` — връзка между статия и автор;
- `hasPublicationType` — връзка между статия и тип публикация;
- `broaderThan` / `narrowerThan` — йерархични връзки между MeSH термини.

5.3 5.3. Данни, използвани за графа

За всяка статия се използват следните полета:

```
pmid
title
abstract
year
journal
publication_types
mesh_terms
```

Най-важното поле за knowledge graph частта е:

```
mesh_terms
```

То съдържа списък от медицински понятия, чрез които статията е индексирана.

6 6. Изграждане на Article–MeSH knowledge graph

Процесът на изграждане на графа преминава през няколко стъпки.

6.1 6.1. Зареждане на статии

Системата зарежда локално кеширани PubMed статии от JSON файл:

```
data/pubmed_articles.json
```

Всяка статия трябва да има поне PMID и списък от MeSH термини. Статии без MeSH термини могат да бъдат пропуснати или включени само като изолирани article възли.

6.2 6.2. Нормализация на MeSH термините

Преди добавяне към графа MeSH термините се нормализират, за да се избегнат дублирания. Примерни операции:

- премахване на излишни интервали;
- превръщане към lowercase формат;
- замяна на интервали със символ _;
- премахване на празни стойности.

Пример:

```
"Cerebral Palsy" -> "cerebral_palsy"  
"Body Composition" -> "body_composition"
```

6.3 6.3. Добавяне на възли и ребра

За всяка статия се създава article възел:

```
article:<PMID>
```

За всеки MeSH термин се създава MeSH възел:

```
mesh:<normalized_term>
```

След това се добавя ребро между статията и всеки неин MeSH термин:

```
article:<PMID> --hasMeSHTerm--> mesh:<term>
```

6.4 6.4. Общ алгоритъм

```
for article in articles:
    article_node = "article:" + article.pmid
    add_node(article_node, type="Article")

    for mesh_term in article.mesh_terms:
        mesh_node = "mesh:" + normalize(mesh_term)
        add_node(mesh_node, type="MeSHTerm")
        add_edge(article_node, mesh_node, relation="hasMeSHTerm")
```


Резултатът е двуделен граф, в който article възлите са свързани с MeSH възли. Две статии не са директно свързани, но могат да бъдат близки чрез общи или сходни MeSH термини.

6.5 6.5. Визуализация на Article–MeSH графа

За демонстрация проектът включва интерактивна HTML визуализация:

nutri-evidence-agent/docs/article_mesh_graph.html

Тъй като pdfLaTeX не може директно да вгражда HTML файлове, в документа е включена статична TikZ версия на същата визуализация. Сините възли са PubMed статии, зелените възли са MeSH термини, а ребрата показват релацията `hasMeSHTerm`.



Фигура 1: Статична версия на интерактивната Article–MeSH визуализация от docs/article_mesh_graph.html.

7 7. MeSH overlap baseline

Преди използване на `node2vec` е полезно да се реализира прост baseline, базиран на припокриване между MeSH термините на две статии.

Ако имаме две статии A и B , техните множества от MeSH термини са M_A и M_B . Сходството може да се изчисли чрез Jaccard similarity:

$$J(A, B) = \frac{|M_A \cap M_B|}{|M_A \cup M_B|} \quad (1)$$

Ако две статии имат много общи MeSH термини, тяхната Jaccard стойност ще бъде по-висока.

Предимства на baseline подхода:

- лесен е за имплементация;
- обясним е;
- показва директно кои термини се припокриват;
- служи като база за сравнение с `node2vec`.

Ограничения:

- отчита само директно съвпадение на термини;
 - не използва глобалната структура на графа;
 - не различава често срещани общи термини от по-специфични термини;
 - не намира индиректна близост между статии.
-

8 8. node2vec върху knowledge graph

8.1 8.1. Идея на node2vec

node2vec е алгоритъм за създаване на векторни представяния на възли в граф. Основната идея е графът да се обходи чрез множество random walks. Получените последователности от възли се третират подобно на изречения, а възлите се третират подобно на думи. След това модел, подобен на Word2Vec, се обучава да поставя близки в графа възли близо един до друг във векторното пространство.

В контекста на проекта това означава:

- статии, които споделят подобни MeSH термини, получават близки embeddings;

- статии, които са свързани чрез общи тематични области, могат да бъдат близки дори без директно припокриване на всички термини;
- графовата структура се превръща в числово представяне, подходящо за similarity search.

8.2 8.2. Random walks

node2vec генерира множество random walks от всеки възел. Примерна разходка в Article-MeSH граф може да изглежда така:

```
article:37656239
mesh:cerebral_palsy
article:12345678
mesh:nutritional_status
article:98765432
```

Така моделът научава, че тези статии и термини се срещат в сходен графов контекст.

8.3 8.3. Параметри на node2vec

Основни параметри:

Параметър	Описание
Dimensions	Размерност на embedding вектора, например 64 или 128.
Walk length	Дължина на всяка random walk последователност.
Number of walks	Брой random walks, стартирани от всеки възел.
Window size	Размер на контекстния прозорец при обучението.
p	Return parameter, който контролира вероятността за връщане към предишния възел.
q	In-out parameter, който контролира дали обхождането е по-локално или по-глобално.

Примерна конфигурация:

```
dimensions = 64
walk_length = 30
num_walks = 100
window = 10
p = 1.0
q = 1.0
```

При $p = 1$ и $q = 1$ random walk поведението е балансирано. При други стойности може да се насърчи по-локално или по-глобално изследване на графа.

8.4 8.4. Обучение на embeddings

След генериране на random walks се обучава embedding модел. Всеки възел получава вектор:

```
article:37656239 -> [0.12, -0.04, 0.33, ...]  
mesh:cerebral_palsy -> [0.08, 0.21, -0.10, ...]
```


За препоръчване се използват само embeddings на article възлите, защото крайната цел е системата да препоръчва статии.

8.5 8.5. Визуализация на node2vec embedding пространството


В проекта са добавени и интерактивни HTML визуализации, които показват научените node2vec embeddings:

```
nutri-evidence-agent/docs/node2vec_embedding_overview.html  
nutri-evidence-agent/docs/node2vec_seed_37656239.html  
nutri-evidence-agent/docs/node2vec_seed_35867728.html
```


Тези визуализации не показват директно суровите Article–MeSH ребра. Вместо това те показват проекция на научените node2vec вектори в двумерно пространство чрез PCA. Близки точки в тези графики означават, че съответните article възли са близки в графовото embedding пространство.



Фигура 2: Обща PCA проекция на article node2vec embeddings. Цветовете групират статиите според първоначалната PubMed заявка, а линиите показват висока graph embedding близост.



Фигура 3: Seed-focused node2vec визуализация за PMID 37656239. Оранжевият възел е избраната seed статия, а останалите възли са нейни близки съседни в graph embedding пространството.



Фигура 4: Seed-focused node2vec визуализация за PMID 35867728. Графиката показва как node2vec групира статии за cerebral palsy, nutrition и близки MeSH контексти.

9. Graph-based recommender

Graph-based recommender използва node2vec embeddings, за да намира статии, които са близки в графовото пространство.

9.1 9.1. Recommend by selected article

В този режим потребителят избира seed статия. Системата намира нейния article node:

article:<seed_pmid>

След това изчислява cosine similarity между embedding-a на seed статията и embeddings на всички останали article възли.

$$\text{sim}(A, B) = \frac{\vec{v}_A \cdot \vec{v}_B}{\|\vec{v}_A\| \|\vec{v}_B\|} \quad (2)$$

Крайните резултати се сортират по similarity score и се връщат Top K най-близки статии.

9.2 9.2. Общ процес

```
Selected seed article
|
Find article node in graph
|
Load node2vec embedding for seed node
|
Compare with all article embeddings
|
Sort by cosine similarity
|
Return Top K similar articles
```

9.3 9.3. Изход от recommender-a

Всеки резултат съдържа:

```
pmid
title
year
journal
mesh_terms
graph_score
method
shared_mesh_terms
```

Полето `shared_mesh_terms` е полезно за обяснение на препоръката, защото показва кои медицински понятия свързват seed статията с препоръчаната статия.

10 10. Архитектура на knowledge graph модула

Планираната структура на проекта за графовата част е:

```
src/
  graph/
    article_mesh_graph_builder.py
    node2vec_trainer.py
    graph_recommender.py
    graph_artifacts.py
```

```
recommenders/  
    mesh_overlap_recommender.py  
    hybrid_recommender.py  
evaluation/  
    graph_evaluator.py
```

10.1 10.1. ArticleMeshGraphBuilder

Този компонент отговаря за:

- зареждане на статии;
- нормализиране на MeSH термините;
- създаване на article и MeSH възли;
- добавяне на релации `hasMeSHTerm`;
- записване на графа като artifact.

10.2 10.2. Node2VecTrainer

Този компонент:

- приема готов NetworkX граф;
- стартира node2vec обучение;
- създава embeddings за всички възли;
- запазва модела и embedding файловете;
- позволява повторно използване без ново обучение.

10.3 10.3. GraphRecommender

Този компонент:

- зарежда node2vec embeddings;
 - филтрира само article възли;
 - приема seed PMID;
 - изчислява cosine similarity;
 - връща Top K graph-based препоръки.
-

11 11. Хипотези

11.1 11.1. Хипотеза H1: MeSH термините са подходяща основа за база от знания

Твърдение: PubMed статии и техните MeSH термини могат да бъдат представени като графова база от знания, която отразява домейн връзки в биомедицинската литература.

Очакван резултат: Статии от близки теми ще бъдат свързани чрез общи MeSH възли или чрез близки пътища в графа.

Критерий за отхвърляне: Ако графът е прекалено разреден, съдържа твърде много изолирани възли или не създава полезни връзки между статии, хипотезата се отслабва.

11.2 11.2. Хипотеза H2: node2vec улавя структурна близост между статии

Твърдение: node2vec embeddings върху Article-MeSH граф могат да откриват тематично сходни статии чрез структурата на графа.

Очакван резултат: Graph-based recommender ще връща статии със сходни медицински теми, дори когато текстовете им не са напълно еднакви.

Критерий за отхвърляне: Ако node2vec резултатите са по-слаби от простия MeSH overlap baseline при повечето тестови случаи, хипотезата се отхвърля за текущия dataset.

11.3 11.3. Хипотеза H3: Графовият подход е обясним

Твърдение: Препоръките от графовия recommender могат да бъдат обяснени чрез общи MeSH термини и пътища в графа.

Очакван резултат: За всяка препоръчана статия системата може да покаже кои MeSH термини я свързват със seed статията.

Критерий за отхвърляне: Ако node2vec връща сходни статии без видими общи понятия или обясними връзки, обяснимостта на подхода е ограничена.

12 12. Оценяване

Оценяването на knowledge graph частта може да се извърши чрез сравнение на няколко метода:

- MeSH overlap baseline;
- Graph node2vec recommender;
- Hybrid recommender, който комбинира semantic и graph score.

12.1 12.1. Evaluation scenario

Основният сценарий за оценка е **Recommend by selected article**. Потребителят избира seed article, а системата трябва да намери сходни статии.

Пример:

Seed article:

PMID 37656239

Low skeletal muscle mass and liver fibrosis in children with cerebral palsy.

Системата сравнява резултатите от различните методи и проверява кои от тях връщат най-релевантни публикации.

12.2 12.2. Метрики

Използват се ranking метрики:

Precision@5

Precision@10

nDCG@5

nDCG@10

MRR

Релевантността може да бъде зададена по скала:

0 = not relevant

1 = somewhat relevant

2 = relevant

3 = highly relevant

За binary метрики може да се използва праг:

relevance >= 2 = relevant

12.3 12.3. Примерна таблица за резултати

Метод	P@5	P@10	nDCG@5	nDCG@10	MRR
MeSH overlap baseline	0.200	0.200	0.678	0.678	0.200
Graph node2vec	0.200	0.200	0.821	0.775	0.500
Hybrid	0.200	0.200	0.770	0.763	0.250

Таблицата показва примерен формат за представяне на резултати. При финалната версия стойностите трябва да се изчислят върху реалните evaluation файлове на проекта.

13 13. Реализация

13.1 13.1. Използвани технологии

За knowledge graph частта се използват:

```
Python 3.10+  
pandas  
numpy  
NetworkX  
node2vec  
gensim  
scikit-learn
```

NetworkX се използва за построяване и съхранение на графа. node2vec и gensim се използват за обучение на embeddings. scikit-learn се използва за cosine similarity и ranking.

13.2 13.2. Данни и artifacts

Графовата част може да генерира следните artifacts:

```
data/artifacts/article_mesh_graph.gpickle  
data/artifacts/node2vec_model.model  
data/artifacts/article_node_embeddings.npy  
data/artifacts/article_node_mapping.json
```

Тези файлове позволяват графът и embeddings да се използват повторно без всяко стартиране да обучава модела отначало.

13.3 13.3. Псевдокод на GraphRecommender

```
def recommend_similar_articles(seed_pmid, top_k):
    seed_node = "article:" + seed_pmid

    if seed_node not in embeddings:
        return []

    seed_vector = embeddings[seed_node]
    scores = []

    for node, vector in embeddings.items():
        if not node.startswith("article:"):
            continue
        if node == seed_node:
            continue

        score = cosine_similarity(seed_vector, vector)
        scores.append((node, score))

    scores.sort(key=lambda x: x[1], reverse=True)
    return scores[:top_k]
```

14 14. Ограничения

Knowledge graph подходът има следните ограничения:

- качеството зависи от наличието и пълнотата на MeSH термините;
 - нови PubMed статии може да нямат пълни MeSH annotations;
 - Article–MeSH графът е сравнително прост и не използва пълната MeSH йерархия;
 - node2vec може да намира структурна близост, която не винаги означава реална научна релевантност;
 - често срещани MeSH термини като **Humans** или **Child** могат да създадат твърде общи връзки;
 - random walk параметрите влияят върху качеството на embeddings;
 - графът не оценява методологично качество, risk of bias или сила на доказателствата.
-

15 15. Бъдеща работа

В бъдеща версия knowledge graph частта може да бъде разширена чрез:

- добавяне на MeSH hierarchy relations;
 - използване на RDF triples;
 - SPARQL заявки върху графа;
 - добавяне на authors, journals и publication types като възли;
 - претегляне на ръбовете според важността на MeSH термините;
 - филтриране на твърде общи MeSH terms;
 - сравнение между node2vec, DeepWalk и GraphSAGE;
 - визуализация на графа;
 - генериране на обяснения чрез shortest paths между статии;
 - комбиниране на graph embeddings със semantic embeddings.
-

16 16. Очакван принос на проекта

Проектът демонстрира как знания от биомедицинска област могат да бъдат представени и използвани чрез графова база от знания. Основният принос е в комбинирането на:

Knowledge representation
Article--MeSH graph
Controlled medical vocabulary
Graph-based recommendation
node2vec embeddings
Similarity search
Explainable recommendations
Evaluation with ranking metrics

Това прави проекта подходящ за дисциплината „Бази от знания“, защото показва практически пример за изграждане, обработка и използване на структурирани знания.

17 17. Заключение

Графовата част на *NutriEvidence Agent* представя PubMed статии и MeSH термини като база от знания. Чрез Article–MeSH knowledge graph системата може да моделира

връзки между публикации и медицински понятия. node2vec превръща тази структура във векторно пространство, което позволява намиране на сходни статии чрез graph-based similarity.

За предмета „Бази от знания“ проектът е ценен, защото демонстрира целия процес: извличане на структурирани знания, моделиране като граф, обучение на графови embeddings, препоръчване на обекти и оценяване на резултатите. Въпреки ограниченията, този подход дава основа за по-богати knowledge graph решения, включително RDF, SPARQL, йерархии на понятия и обясними пътища между публикации.